РК1

Вариант 7.

- Студент - Кожуро Б.Е.
- Группа - ИУ5-21М
- Вариант - 7

Задача №7.

Для набора данных проведите устранение пропусков для одного (произвольного) числового признака с использованием метода заполнения медианой.

Датасет https://www.kaggle.com/datasets/syedanwarafridi/vehicle-sales-data (https://www.kaggle.com/datasets/syedanwarafridi/vehicle-sales-data)

1. year int64
2. make object
3. model object
4. trim object
5. body object
6. transmission object
7. vin object
8. state object
9. condition float64
10. odometer float64
11. color object
12. interior object
13. seller object
14. mmr int64
15. sellingprice int64
16. saledate object

Ввод [3]:
```
import numpy as np
import pandas as pd
import seaborn as sns
import matplotlib.pyplot as plt
import scipy.stats as stats
%matplotlib inline
sns.set(style="ticks")
```

Ввод [4]:
```
data = pd.read_csv('car_prices.csv', sep=",")
```

Ввод [5]:
```
data.isna().sum()
```

Out[5]:
```
year              0
make          10301
model         10399
trim          10651
body          13195
transmission  65352
vin               4
state             0
condition     11820
odometer         94
color           749
interior        749
seller            0
mmr              38
sellingprice     12
saledate         12
dtype: int64
```

Ввод [6]:
```
data.dtypes
```

Out[6]:
```
year             int64
make            object
model           object
trim            object
body            object
transmission    object
vin             object
state           object
condition      float64
odometer       float64
color           object
interior        object
seller          object
mmr            float64
sellingprice   float64
saledate        object
dtype: object
```

Ввод [7]:
```
data.shape
```

Out[7]:
```
(558837, 16)
```

Заполним модой значение condition.

Ввод [8]:
```
temp_data = data[['condition']].values
size = temp_data.shape[0]

from sklearn.impute import SimpleImputer

imputer = SimpleImputer(strategy='median')
all_data = imputer.fit_transform(temp_data)

median_df = data.copy()
median_df['condition'] = all_data
```

Ввод [9]:
```
median_df.isna().sum()
```

Out[9]:
```
year              0
make          10301
model         10399
trim          10651
body          13195
transmission  65352
vin               4
state             0
condition         0
odometer         94
color           749
interior        749
seller            0
mmr              38
sellingprice     12
saledate         12
dtype: int64
```

###Задача №27. Для набора данных для одного (произвольного) числового признака проведите обнаружение и замену (найденными верхними и нижними границами) выбросов на основе 5% и 95% квантилей.

Ввод [10]:
```
def diagnostic_plots(df, variable, title):
    fig, ax = plt.subplots(figsize=(10,7))
    # гистограмма
    plt.subplot(2, 2, 1)
    df[variable].hist(bins=30)
    ## Q-Q plot
    plt.subplot(2, 2, 2)
    stats.probplot(df[variable], dist="norm", plot=plt)
    # ящик с усами
    plt.subplot(2, 2, 3)
    sns.violinplot(x=df[variable])
    # ящик с усами
    plt.subplot(2, 2, 4)
    sns.boxplot(x=df[variable])
    fig.suptitle(title)
    plt.show()
```

Ввод [11]:
```
diagnostic_plots(median_df, 'mmr','Manheim Market Report, possibly indicatir
```

```
<ipython-input-10-766c933c159f>:4: MatplotlibDeprecationWarning: Auto-remo
val of overlapping axes is deprecated since 3.6 and will be removed two mi
nor releases later; explicitly call ax.remove() as needed.
  plt.subplot(2, 2, 1)
```

Manheim Market Report, possibly indicating the estimated market value of the vehicle.

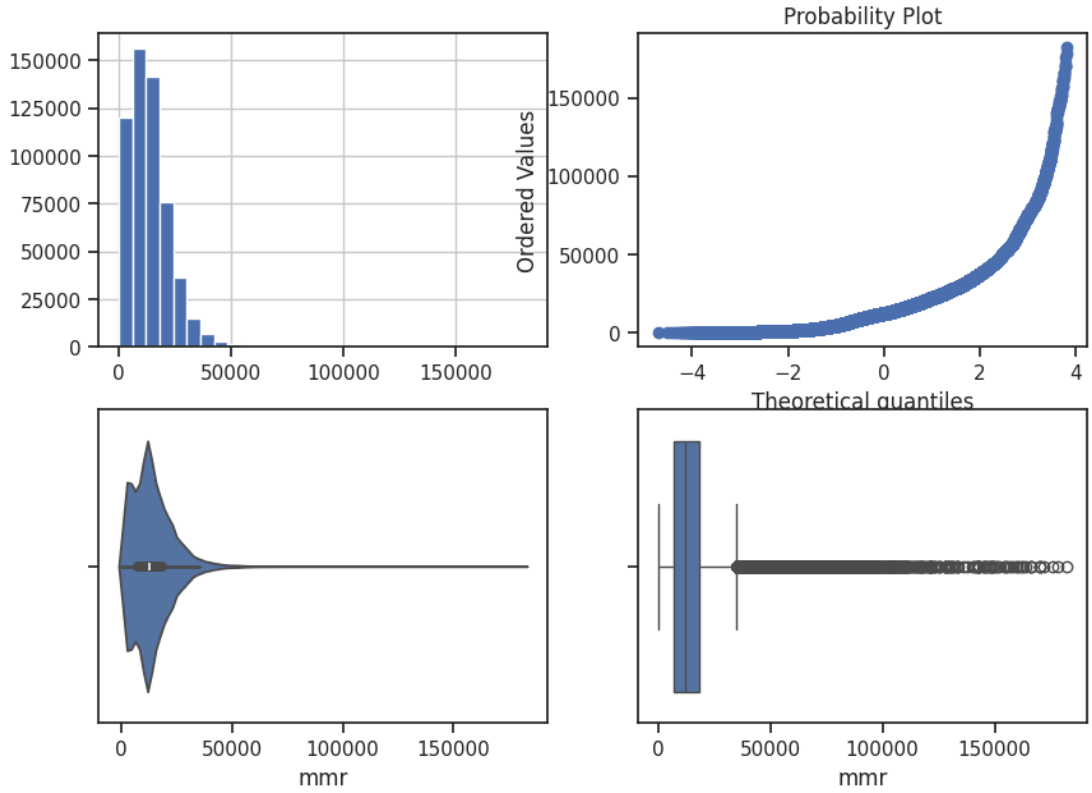

Распределение отличается от нормального, при этом ассиметричное - лучше было бы использовать IRQ.

Ввод [12]:
```
# Функция вычисления верхней и нижней границы выбросов
def get_outlier_boundaries(df, col):
    lower_boundary = df[col].quantile(0.05)
    upper_boundary = df[col].quantile(0.95)
    return lower_boundary, upper_boundary
```

Ввод [13]:

```
col = 'mmr'
lower_boundary, upper_boundary = get_outlier_boundaries(median_df, col)
median_df[col] = np.where(median_df[col] > upper_boundary, upper_boundary,
title = 'Поле-{}, метод-{}, строк-{}'.format(col, '95th', median_df.shape[0]
diagnostic_plots(median_df, col, title)
```

```
<ipython-input-10-766c933c159f>:4: MatplotlibDeprecationWarning: Auto-remo
val of overlapping axes is deprecated since 3.6 and will be removed two mi
nor releases later; explicitly call ax.remove() as needed.
  plt.subplot(2, 2, 1)
```

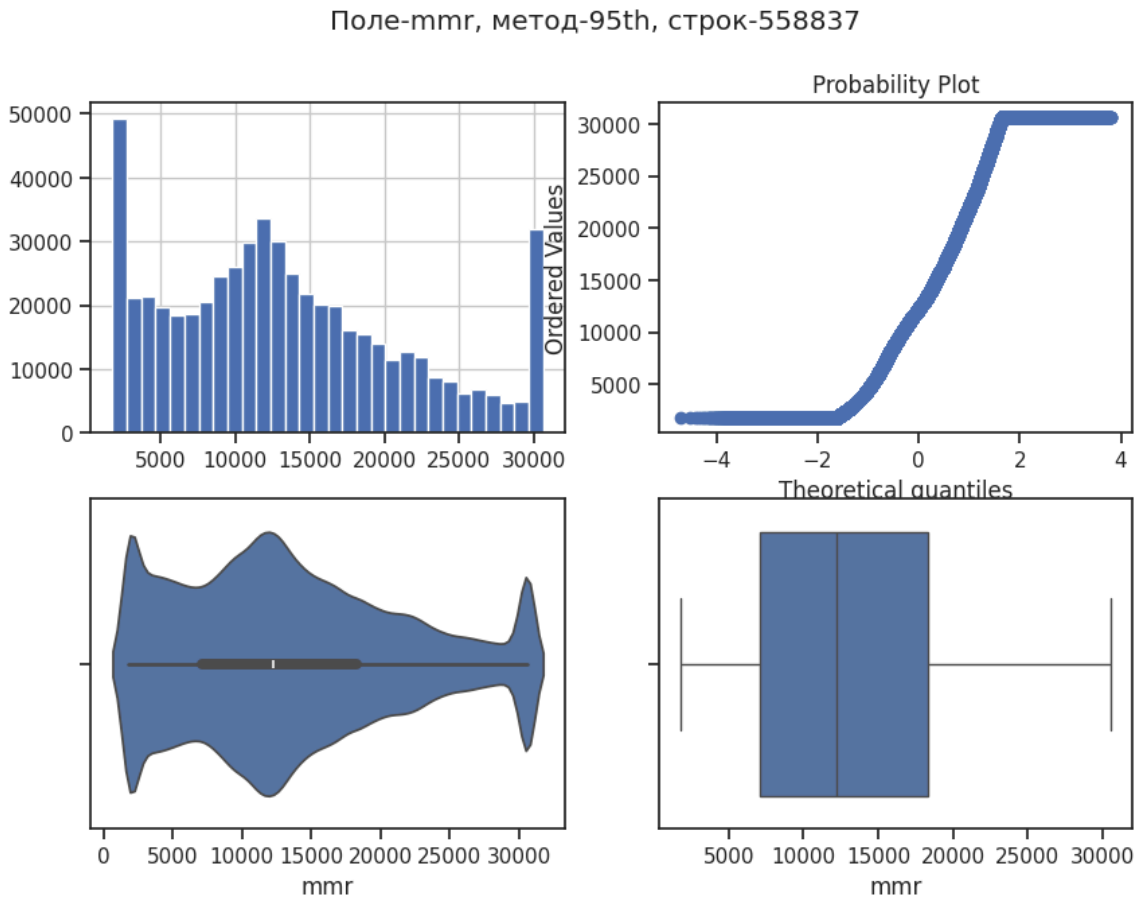

Ввод [14]:
```
# Диаграмма рассеяния
fig, ax = plt.subplots(figsize=(10,10))
sns.scatterplot(ax=ax, x='condition', y='sellingprice', data = median_df)
plt.xlabel('condition')
plt.ylabel('sellingprice')
```

Out[14]:
```
Text(0, 0.5, 'sellingprice')
```