РК1

Вариант 9.

- Студент Кожуро Б.Е.
- Группа ИУ5-21М
- Вариант 9

Задача №9. ¶

Для набора данных проведите устранение пропусков для одного (произвольного) числового признака с использованием метода заполнения "хвостом распределения".

Датасет https://www.kaggle.com/datasets/syedanwarafridi/vehicle-sales-data (https://www.kaggle.com/datasets/syedanwarafridi/vehicle-sales-data)

- 1. year int64
- 2. make object
- 3. model object
- 4. trim object
- 5. body object
- 6. transmission object
- 7. vin object
- 8. state object
- 9. condition float64
- 10. odometer float64
- 11. color object
- 12. interior object
- 13. seller object
- 14. mmr int64
- 15. sellingprice int64
- 16. saledate object

```
Ввод [49]: import numpy as np import pandas as pd import seaborn as sns import matplotlib.pyplot as plt import scipy.stats as stats %matplotlib inline sns.set(style="ticks")
```

```
Ввод [50]: data = pd.read_csv('car_prices.csv', sep=",")
```

```
Ввод [51]: data.isna().sum()
 Out[51]: year
                                0
           make
                            10301
           model
                            10399
           trim
                            10651
           body
                            13195
           transmission
                            65352
           vin
                                4
                                0
           state
           condition
                            11820
           odometer
                               94
                              749
           color
                              749
           interior
           seller
                                0
                               38
           mmr
           sellingprice
                               12
           saledate
                               12
           dtype: int64
Ввод [52]: data.dtypes
 Out[52]: year
                              int64
                             object
           make
           model
                             object
           trim
                             object
                             object
           body
           transmission
                             object
           vin
                             object
           state
                             object
                            float64
           condition
           odometer
                            float64
                             object
           color
           interior
                             object
                             object
           seller
           mmr
                            float64
                            float64
           sellingprice
                             object
           saledate
           dtype: object
Ввод [53]: data.shape
```

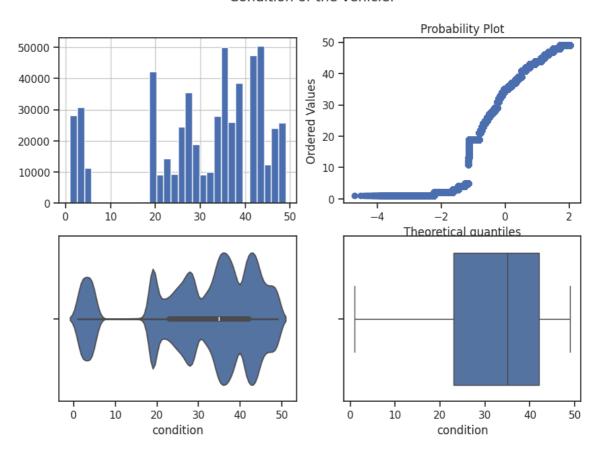
Out[53]: (558837, 16)

```
Ввод [54]: def diagnostic_plots(df, variable, title):
               fig, ax = plt.subplots(figsize=(10,7))
               # гистограмма
               plt.subplot(2, 2, 1)
               df[variable].hist(bins=30)
               ## Q-Q plot
               plt.subplot(2, 2, 2)
               stats.probplot(df[variable], dist="norm", plot=plt)
               # ящик с усами
               plt.subplot(2, 2, 3)
               sns.violinplot(x=df[variable])
               # ящик с усами
               plt.subplot(2, 2, 4)
               sns.boxplot(x=df[variable])
               fig.suptitle(title)
               plt.show()
```

Ввод [55]: diagnostic_plots(data, 'condition','Condition of the vehicle.')

<ipython-input-54-766c933c159f>:4: MatplotlibDeprecationWarning: Auto-remo
val of overlapping axes is deprecated since 3.6 and will be removed two mi
nor releases later; explicitly call ax.remove() as needed.
 plt.subplot(2, 2, 1)

Condition of the vehicle.



Заполним модой значение condition.

```
Ввод [56]:
          temp_data = data[['condition']].values
           size = temp_data.shape[0]
           IQR = data['condition'].quantile(0.75) - data['condition'].quantile(0.25)
           from sklearn.impute import SimpleImputer
           imputer = SimpleImputer(strategy='constant', fill_value=data['condition'].qu
           all_data = imputer.fit_transform(temp_data)
           median df = data.copy()
           median df['condition'] = all data
Ввод [57]: median_df.isna().sum()
 Out[57]: year
                           10301
           make
           model
                           10399
           trim
                           10651
           body
                           13195
           transmission
                           65352
           vin
                               4
           state
                               0
                               0
           condition
           odometer
                              94
                             749
           color
                             749
           interior
           seller
                               0
           mmr
                              38
           sellingprice
                              12
           saledate
                              12
           dtype: int64
           ###Задача №29. Для набора данных проведите удаление константных и
           псевдоконстантных признаков.
Ввод [58]: from sklearn.feature_selection import VarianceThreshold
           selector 1211 = VarianceThreshold(threshold=0.15)
           selector_1211.fit(median_df[['year','condition','odometer']])
           # Значения дисперсий для каждого признака
           selector 1211.variances
 Out[58]: array([1.57359788e+01, 2.08677136e+02, 2.85139927e+09])
           Достаточно малых дисперсий нет, добавим колонку.
Ввод [59]: pseudovar = np.random.normal(loc=10, scale = 0.1, size = (median df.shape[0]
           median_df.insert(16,"PSV", pseudovar, True)
           selector_1211 = VarianceThreshold(threshold=0.15)
           selector_1211.fit(median_df[['year','condition','odometer', 'PSV']])
           # Значения дисперсий для каждого признака
           selector_1211.variances_
 Out[59]: array([1.57359788e+01, 2.08677136e+02, 2.85139927e+09, 9.95924918e-03])
```

```
Ввод [60]: # Константный и псевдоконстантный признаки удалены
           selector_1211.transform(median_df[['year','condition','odometer', 'PSV']])
 Out[60]: array([[2.0150e+03, 5.0000e+00, 1.6639e+04],
                   [2.0150e+03, 5.0000e+00, 9.3930e+03],
                   [2.0140e+03, 4.5000e+01, 1.3310e+03],
                   [2.0120e+03, 4.8000e+01, 5.0561e+04],
                   [2.0150e+03, 3.8000e+01, 1.6658e+04],
                   [2.0140e+03, 3.4000e+01, 1.5008e+04]])
Ввод [61]: #Удалим колонку
           median_df=median_df.drop(columns = ['PSV'])
Ввод [62]: median_df.shape
 Out[62]: (558837, 16)
Ввод [63]: data.dtypes
 Out[63]: year
                              int64
           make
                             object
                            object
           model
           trim
                            object
           body
                             object
           transmission
                            object
                            object
           vin
                            object
           state
           condition
                            float64
                           float64
           odometer
                            object
           color
           interior
                            object
           seller
                            object
                            float64
           mmr
           sellingprice
                           float64
                            object
           saledate
           dtype: object
```

```
BBOД [64]: # Диаграмма рассеяния
fig, ax = plt.subplots(figsize=(10,10))
sns.scatterplot(ax=ax, x='condition', y='sellingprice', data = median_df)
plt.xlabel('condition')
plt.ylabel('sellingprice')
```

Out[64]: Text(0, 0.5, 'sellingprice')

